

LAPORAN PROJECT AKHIR
PEMBELAJARAN MESIN DASAR
S1 SAINS DATA - UNIVERSITAS NEGERI SURABAYA
SEMESTER GENAP 2025/2026

IDENTITAS PROYEK	
Judul	Analisis Pengaruh Tekanan Akademik terhadap Risiko Burnout Mahasiswa Menggunakan Algoritma Support Vector Machine dan Random Forest
Topik	Academic Pressure Analysis
Identitas Penyusun	1. Putri Sofiyatus Salwa (24031554112) 2. Adisti Eka Nabila (24031554119) 3. Cintiya Agustin Nareswari (24031554218)
Kelas	2024B

1. PENDAHULUAN

1.1. Latar Belakang

Kesehatan mental mahasiswa menjadi isu yang semakin penting dalam lingkungan pendidikan tinggi karena tingginya tekanan akademik, tuntutan sosial, serta ekspektasi keluarga. Kondisi tersebut dapat menyebabkan mahasiswa mengalami stres, kecemasan, depresi, hingga burnout akademik yang berdampak pada penurunan motivasi belajar dan performa akademik. Burnout akademik merupakan kondisi kelelahan emosional, mental, dan fisik akibat tekanan akademik yang terjadi secara terus-menerus. Oleh karena itu, diperlukan upaya deteksi dini yang lebih efektif untuk membantu mengurangi risiko gangguan kesehatan mental pada mahasiswa melalui pemanfaatan teknologi dan machine learning [1].

Beberapa penelitian menunjukkan bahwa burnout mahasiswa dipengaruhi oleh berbagai faktor akademik dan psikologis seperti tekanan ujian, stres finansial, kualitas tidur, kondisi emosional, dan dukungan sosial. Academic burnout dipengaruhi oleh faktor multidimensi yang kompleks sehingga memerlukan pendekatan analisis yang mampu mengolah data secara akurat dan efisien [2]. Seiring perkembangan teknologi, machine learning mulai banyak digunakan untuk memprediksi kondisi kesehatan mental mahasiswa karena mampu mengenali pola data yang kompleks. Algoritma machine learning juga terbukti mampu menghasilkan performa klasifikasi yang baik dalam prediksi kesehatan mental dan burnout mahasiswa [3].

Penelitian ini dilakukan untuk membandingkan performa algoritma Support Vector Machine (SVM) dan Random Forest dalam memprediksi risiko burnout mahasiswa berdasarkan tekanan akademik dan faktor psikologis. Algoritma SVM dipilih karena mampu menangani data multidimensi dan kompleks, sedangkan Random Forest memiliki performa yang stabil serta mampu menghasilkan feature importance untuk mengetahui faktor yang paling berpengaruh terhadap burnout mahasiswa [4][5]. Penelitian menggunakan Student Mental Health and Burnout Dataset yang memiliki berbagai variabel akademik, psikologis, dan gaya hidup mahasiswa. Hasil penelitian diharapkan dapat membantu proses deteksi dini burnout mahasiswa serta menjadi bahan pertimbangan bagi institusi pendidikan dalam menjaga kesehatan mental mahasiswa.

1.2. Rumusan Masalah dan Tujuan

A. Rumusan Masalah

Dari latar belakang yang telah dipaparkan, diperoleh rumusan masalah sebagai berikut:

1. Bagaimana pengaruh tekanan akademik dan faktor psikologis terhadap risiko burnout mahasiswa?
2. Bagaimana performa algoritma Support Vector Machine (SVM) dan Random Forest dalam memprediksi risiko burnout mahasiswa?
3. Faktor apa saja yang paling berpengaruh terhadap risiko burnout mahasiswa berdasarkan feature importance?

B. Tujuan

Berdasarkan rumusan masalah tersebut, tujuan penelitian ini ialah sebagai berikut:

1. Menganalisis pengaruh tekanan akademik dan faktor psikologis terhadap risiko burnout mahasiswa.
2. Membandingkan performa algoritma Support Vector Machine (SVM) dan Random Forest dalam memprediksi risiko burnout mahasiswa.
3. Mengidentifikasi faktor-faktor yang paling berpengaruh terhadap risiko burnout mahasiswa menggunakan feature importance.

2. Metodologi

2.1. Eksplorasi Dataset

1. Informasi Dataset

Dataset yang digunakan dalam penelitian ini adalah Student Mental Health and Burnout Dataset yang diperoleh dari platform Kaggle dengan format CSV dan dapat diakses melalui link berikut: <https://www.kaggle.com/datasets/sharmajicoder/student-mental-health-and-burnout>. Dataset ini merupakan dataset sintesis yang dirancang untuk menggambarkan hubungan antara faktor akademik, gaya hidup, kondisi psikologis, dan tingkat burnout pada mahasiswa.

Dataset terdiri dari 1.000.000 data dengan 20 atribut. Berdasarkan hasil pemeriksaan, dataset memiliki tiga jenis tipe data, yaitu 16 atribut bertipe float64, 2 atribut bertipe int64, dan 3 atribut bertipe object. Atribut kategorikal dalam dataset terdiri dari gender, academic_year, dan risk_level, sedangkan atribut lainnya berupa data numerik. Dalam penelitian ini, atribut risk_level digunakan sebagai variabel target yang akan diklasifikasikan ke dalam tiga kelas, yaitu Low, Medium, dan High. Sementara itu, atribut lainnya digunakan sebagai variabel prediktor dalam proses pelatihan dan pengujian model machine learning.

2. Data Cleaning

Tahap data cleaning dilakukan untuk memastikan kualitas data yang digunakan dalam proses pelatihan dan pengujian model. Berdasarkan hasil pemeriksaan, seluruh atribut pada dataset tidak memiliki nilai yang hilang (missing value) dan tidak ditemukan data yang terduplikasi (duplicate data). Dengan demikian, dataset telah memenuhi kualitas data yang baik dan dapat langsung digunakan pada tahap pemodelan tanpa memerlukan proses penanganan nilai hilang maupun penghapusan data duplikat.


3. Sampling

Dataset awal terdiri dari 1.000.000 data sehingga memerlukan waktu komputasi yang cukup besar pada proses pelatihan model. Oleh karena itu dilakukan proses sampling untuk mengurangi ukuran data tanpa menghilangkan karakteristik distribusi kelas. Metode yang digunakan adalah stratified sampling sebesar 50%, sehingga proporsi masing-masing kelas pada variabel target (risk_level) tetap dipertahankan. Penggunaan 500.000 data dinilai masih mampu merepresentasikan karakteristik dataset asli sekaligus mengurangi beban komputasi

selama proses pelatihan dan evaluasi model. Berikut hasil proses sampling yang ditunjukkan oleh tabel 1.

Tabel 1. Sampling Data	
Data	Jumlah
Dataset Awal	1.000.000
Dataset Setelah Sampling	500.000

2.2. Tahapan Penelitian



Gambar 1. Alur Penelitian

1. Data Collection

Tahap pertama dalam penelitian ini adalah pengumpulan data menggunakan *Student Mental Health and Burnout Dataset* yang memuat informasi akademik, psikologis, dan gaya hidup mahasiswa. Dataset ini digunakan karena sesuai dengan tujuan penelitian, yaitu mengklasifikasikan tingkat risiko burnout mahasiswa ke dalam kategori Low, Medium, dan High. Variabel yang tersedia dalam dataset mendukung analisis faktor tekanan akademik, stres, kecemasan, depresi, kualitas tidur, dukungan sosial, dan kondisi mental mahasiswa. Penggunaan data kesehatan mental mahasiswa dalam machine learning relevan karena pendekatan komputasional dapat membantu proses deteksi dini kondisi psikologis secara lebih efektif [1].

2. Data Understanding dan Data cleaning

Tahap data understanding dilakukan untuk memahami struktur dataset, jumlah data, tipe data, serta karakteristik setiap variabel yang digunakan dalam penelitian. Pada tahap ini dilakukan pemeriksaan ukuran dataset, informasi kolom, nilai kosong, data duplikat, serta nilai unik pada fitur kategorikal seperti gender, academic_year, dan risk_level. Hasil pemeriksaan menunjukkan bahwa dataset tidak memiliki missing value maupun duplicate data, sehingga data dapat digunakan tanpa proses imputasi atau penghapusan data duplikat. Tahap ini penting karena kualitas data sangat memengaruhi performa model machine learning dalam memprediksi kondisi kesehatan mental mahasiswa [6].

3. Exploratory Data Analysis (EDA)

Tahap EDA dilakukan untuk memahami distribusi data dan hubungan antarvariabel sebelum proses pemodelan. Visualisasi yang digunakan meliputi distribusi target risk_level, distribusi fitur kategorikal, histogram fitur numerik, boxplot untuk deteksi outlier, correlation heatmap, serta scatterplot antara exam_pressure dan burnout_score. Hasil EDA menunjukkan

bahwa distribusi target tidak seimbang, dengan kelas Low sebagai kelas mayoritas dan kelas High sebagai kelas minoritas. Analisis eksploratif seperti ini penting dalam penelitian kesehatan mental karena dapat membantu mengidentifikasi pola awal pada faktor akademik dan psikologis mahasiswa [7].

4. Sampling

Tahap sampling dilakukan karena dataset awal memiliki jumlah data yang sangat besar, yaitu 1.000.000 data, sehingga proses pelatihan model dapat memerlukan waktu komputasi yang cukup lama. Penelitian ini menggunakan sampling sebesar 50% dengan mempertahankan proporsi kelas berdasarkan risk_level. Setelah proses sampling, jumlah data yang digunakan menjadi 500.000 data dengan distribusi kelas yang tetap merepresentasikan kondisi dataset awal. Penggunaan sampling tetap dapat dilakukan selama proporsi kelas dijaga, terutama pada penelitian machine learning dengan dataset berukuran besar dan tidak seimbang [3].

5. Leakage Analysis

Tahap leakage analysis dilakukan untuk mengidentifikasi fitur yang berpotensi menyebabkan kebocoran informasi terhadap target. Pada penelitian ini, fitur burnout_score, mental_health_index, dan dropout_risk dihapus karena memiliki hubungan yang sangat dekat dengan risk_level. Jika fitur tersebut tetap digunakan, model dapat memperoleh informasi yang terlalu langsung terhadap target sehingga hasil prediksi menjadi tidak realistis. Penghapusan fitur leakage dilakukan agar model benar-benar belajar dari faktor akademik dan psikologis yang relevan, bukan dari variabel yang secara tidak langsung sudah merepresentasikan target [2].

6. Preprocessing

Tahap preprocessing dilakukan setelah fitur leakage dihapus dan data siap digunakan untuk proses pemodelan. Pada tahap ini, fitur input dan target dipisahkan, dengan X sebagai kumpulan fitur dan y sebagai target risk_level. Target risk_level kemudian diubah menjadi bentuk numerik melalui label mapping, yaitu Low = 0, Medium = 1, dan High = 2. Proses ini diperlukan karena algoritma machine learning membutuhkan target dalam bentuk numerik untuk melakukan proses klasifikasi [8].

7. Train-Test Split

Tahap train-test split dilakukan untuk membagi data menjadi data latih dan data uji. Data dibagi dengan proporsi 80% untuk training dan 20% untuk testing. Pembagian data dilakukan menggunakan stratify agar proporsi kelas Low, Medium, dan High tetap seimbang pada data training maupun data testing. Tahap ini penting agar evaluasi model dapat dilakukan secara objektif terhadap data yang belum pernah dipelajari oleh model [9].

8. Data Transformation

Tahap data transformation dilakukan untuk mengubah fitur agar sesuai dengan kebutuhan algoritma machine learning. Fitur numerik ditransformasikan menggunakan StandardScaler agar memiliki skala yang lebih seragam, sedangkan fitur gender diubah menggunakan OneHotEncoder karena termasuk data kategorikal nominal. Fitur academic_year diubah menggunakan OrdinalEncoder karena memiliki urutan tingkat tahun akademik dari 1 sampai 4. Transformasi data diperlukan karena model seperti SVM dan Random Forest membutuhkan input dalam bentuk numerik agar dapat memproses data dengan baik [4].

9. Imbalance Handling

Tahap imbalance handling dilakukan karena distribusi target risk_level tidak seimbang, terutama pada kelas High yang memiliki jumlah data paling sedikit. Penelitian ini menggunakan SMOTE untuk menambah data sintetis pada kelas minoritas selama proses training. Selain itu, class_weight='balanced' juga digunakan agar model memberikan perhatian lebih besar terhadap kelas yang jumlah datanya lebih sedikit. Penanganan data tidak seimbang penting dilakukan karena model dapat cenderung memprioritaskan kelas mayoritas dan gagal mengenali kelas minoritas dengan baik [3].

10. Model Development dan Hyperparameter Tuning

Tahap model development dilakukan dengan membangun dua model klasifikasi, yaitu Support Vector Machine (SVM) dan Random Forest. Model SVM dikembangkan menggunakan pendekatan LinearSVC dengan parameter awal $C = 1$, max_iter = 2000, loss = squared_hinge, serta class_weight = balanced untuk membantu model memperhatikan kelas minoritas. SVM digunakan karena mampu membentuk batas pemisah antar kelas dan sesuai untuk permasalahan klasifikasi dengan banyak fitur. Penggunaan SVM dalam prediksi stres dan kesehatan mental mahasiswa juga dinilai efektif karena mampu menangani data kompleks pada kasus klasifikasi psikologis [4].

Model Random Forest dikembangkan sebagai model pembanding dengan parameter awal n_estimators = 100, max_depth = 20, min_samples_leaf = 2, min_sample_split = 2, max_feature = sqrt, serta class_weight = balanced. Model ini bekerja dengan membangun banyak decision tree dan menggabungkan hasil prediksinya untuk menghasilkan klasifikasi akhir yang lebih stabil. Random Forest digunakan karena mampu menangani hubungan non-linear antar fitur serta menyediakan informasi feature importance untuk mengetahui faktor yang paling berpengaruh terhadap risiko burnout mahasiswa. Pemilihan Random Forest juga didukung oleh penelitian sebelumnya yang menunjukkan bahwa algoritma ini memiliki performa baik dalam klasifikasi kesehatan mental dan burnout mahasiswa [2][5].

Tahap hyperparameter tuning dilakukan untuk memperoleh kombinasi parameter terbaik pada model SVM dan Random Forest agar performa klasifikasi menjadi lebih optimal. Proses tuning menggunakan RandomizedSearchCV dengan 3-fold cross validation dan metrik utama F1 Macro, karena dataset memiliki distribusi kelas yang tidak seimbang. Pada model SVM, parameter yang diuji meliputi nilai C dan loss, sedangkan pada Random Forest parameter yang diuji meliputi n_estimators, max_depth, min_samples_leaf, min_samples_split, dan max_features. Penggunaan tuning parameter penting dalam penelitian klasifikasi kesehatan mental karena pemilihan konfigurasi model yang tepat dapat memengaruhi kemampuan model dalam mengenali pola data dan meningkatkan performa prediksi secara keseluruhan [2][5].

11. Evaluation

Tahap evaluation dilakukan untuk mengukur performa setiap model menggunakan classification report, confusion matrix, dan learning curve. Metrik evaluasi yang digunakan meliputi accuracy, precision macro, recall macro, f1 macro, dan recall pada kelas High. F1 Macro digunakan sebagai metrik utama karena dataset memiliki distribusi kelas yang tidak seimbang, sehingga evaluasi tidak hanya bergantung pada kelas mayoritas. Evaluasi dengan beberapa metrik diperlukan agar performa model dapat dianalisis secara lebih menyeluruh, terutama pada kasus klasifikasi kesehatan mental dengan kelas minoritas yang penting untuk dideteksi [1].

12. Feature Importance Analysis

Tahap feature importance dilakukan menggunakan model Random Forest terbaik untuk mengetahui fitur yang paling berpengaruh dalam proses klasifikasi risk_level. Analisis ini

membantu menjawab tujuan penelitian terkait faktor-faktor yang paling berpengaruh terhadap risiko burnout. Penggunaan feature importance pada model Random Forest relevan karena model ini tidak hanya menghasilkan prediksi, tetapi juga dapat memberikan interpretasi terhadap kontribusi masing-masing fitur [10]. Selain itu, analisis feature importance juga dilakukan pada model SVM menggunakan nilai koefisien (*coefficient*) dari LinearSVC untuk mengetahui pengaruh setiap fitur terhadap proses klasifikasi. Hasil feature importance dari kedua model kemudian dibandingkan untuk melihat konsistensi fitur-fitur dominan yang berkontribusi terhadap tingkat risiko burnout mahasiswa.


13. Model Comparison

Tahap model comparison dilakukan untuk membandingkan performa seluruh model yang telah dibangun, yaitu SVM Baseline, SVM Tuned, Random Forest Baseline, dan Random Forest Tuned. Perbandingan dilakukan menggunakan beberapa metrik evaluasi, yaitu accuracy, precision macro, recall macro, F1 macro, dan recall pada kelas High. Penggunaan beberapa metrik diperlukan karena dataset memiliki distribusi kelas yang tidak seimbang, sehingga evaluasi tidak hanya bergantung pada accuracy saja. Tahap ini bertujuan untuk menentukan model dengan performa paling seimbang dalam mengklasifikasikan tingkat risiko burnout mahasiswa berdasarkan seluruh kelas target [3][6].

3. Hasil dan Analisis

3.1 Exploratory Data Analysis


1. Distribusi Target



Gambar 2. Distribusi Target Risk Level

Berdasarkan Gambar 2, terlihat bahwa distribusi data pada variabel `risk_level` tidak seimbang, di mana kategori Low mendominasi dengan jumlah sekitar 766.644 data (76,66%), diikuti kategori Medium sebanyak 218.276 data (21,83%), sedangkan kategori High hanya sekitar 15.080 data (1,51%) dari total dataset. Kondisi ini menunjukkan adanya class imbalance, yaitu ketidakseimbangan jumlah data antar kelas target, sehingga model berpotensi lebih mudah mempelajari pola pada kelas mayoritas dibandingkan kelas minoritas. Oleh karena itu, pada tahap pemodelan digunakan teknik SMOTE (Synthetic Minority Oversampling Technique) untuk membantu menyeimbangkan distribusi kelas sehingga model dapat mengklasifikasikan seluruh kategori risiko burnout dengan lebih baik.


2. Distribusi Gender



Gambar 3. Distribusi Gender Mahasiswa

Berdasarkan Gambar 3, terlihat bahwa distribusi data berdasarkan gender relatif seimbang antara kategori Male dan Female, yang masing-masing berjumlah sekitar 480 ribu data. Sementara itu, kategori Other memiliki jumlah yang jauh lebih sedikit dibandingkan dua kategori lainnya, yaitu sekitar 40 ribu data. Distribusi yang cukup seimbang pada kategori Male dan Female menunjukkan bahwa dataset memiliki representasi yang baik untuk kedua kelompok tersebut, sehingga dapat membantu model dalam mempelajari pola risiko burnout tanpa dominasi yang berlebihan dari salah satu jenis kelamin. Namun, jumlah data pada kategori Other yang lebih sedikit perlu diperhatikan karena dapat memengaruhi kemampuan model dalam mengenali karakteristik kelompok tersebut secara optimal.


3. Distribusi Academic Year



Gambar 4. Distribusi Academic Year Mahasiswa

Berdasarkan Gambar 4, terlihat bahwa jumlah data pada setiap kategori `academic_year` memiliki distribusi yang relatif seimbang. Mahasiswa tahun pertama, kedua, ketiga, dan keempat masing-masing memiliki jumlah data sekitar 250 ribu data. Kondisi ini menunjukkan bahwa dataset telah merepresentasikan mahasiswa dari berbagai tingkat akademik secara merata sehingga tidak ada satu kelompok yang mendominasi data. Distribusi yang seimbang ini juga memberikan keuntungan dalam proses pemodelan karena model dapat mempelajari karakteristik risiko burnout pada setiap tingkat akademik dengan lebih baik dan mengurangi potensi bias yang disebabkan oleh perbedaan jumlah data antar kategori.


4. Histogram Numerik



Gambar 5. Distribusi Fitur Numerik

Berdasarkan Gambar 5, terlihat bahwa setiap fitur numerik memiliki pola distribusi yang berbeda. Variabel `exam_pressure`, `stress_level`, dan `sleep_hours` cenderung memiliki distribusi yang mendekati normal dengan konsentrasi data berada pada nilai tengah. Variabel `anxiety_score` menunjukkan sebagian besar mahasiswa memiliki tingkat kecemasan pada rentang rendah hingga sedang. Sementara itu, `depression_score` dan `burnout_score` memiliki distribusi yang condong ke kanan (*right-skewed*), yang menunjukkan bahwa sebagian besar mahasiswa memiliki tingkat depresi dan burnout yang rendah, sedangkan hanya sebagian kecil yang berada pada tingkat yang tinggi. Secara umum, distribusi ini menunjukkan bahwa kondisi psikologis mahasiswa dalam dataset cukup beragam sehingga dapat memberikan informasi yang baik bagi model dalam mempelajari pola risiko burnout mahasiswa.


5. Distribusi Outlier (Boxplot)



Gambar 6. Distribusi Outlier

Berdasarkan visualisasi pada Gambar 6, terlihat bahwa sebagian besar fitur memiliki distribusi data yang cukup baik, namun terdapat beberapa *outlier* terutama pada variabel `stress_level`, `anxiety_score`, `depression_score`, dan `burnout_score`. Keberadaan *outlier* menunjukkan adanya sejumlah mahasiswa yang memiliki nilai jauh di atas atau di bawah mayoritas data. Variabel `sleep_hours` memiliki median yang relatif lebih tinggi dibandingkan variabel lainnya, sedangkan `exam_pressure` menunjukkan persebaran data yang cukup merata. Namun, pada penelitian ini *outlier* tidak dihapus karena masih dianggap merepresentasikan kondisi nyata mahasiswa dan tidak menunjukkan adanya kesalahan data.

6. Analisis Korelasi (Heatmap Correlation)




Gambar 7. Analisis Korelasi

Berdasarkan heatmap korelasi, terdapat beberapa hubungan yang cukup kuat antarvariabel dalam dataset. Variabel *stress_level* memiliki korelasi positif yang kuat dengan *anxiety_score* (0,76) dan *burnout_score* (0,75), yang menunjukkan bahwa peningkatan tingkat stres cenderung diikuti oleh peningkatan kecemasan dan burnout. Selain itu, *burnout_score* juga berkorelasi positif dengan *anxiety_score* (0,67), *depression_score* (0,64), serta *dropout_risk* (0,69), sehingga faktor-faktor kesehatan mental berperan penting terhadap risiko drop out. Sebaliknya, *mental_health_index* memiliki korelasi negatif yang sangat kuat dengan *stress_level* (-0,95), *anxiety_score* (-0,87), dan *burnout_score* (-0,80), yang menunjukkan bahwa kondisi kesehatan mental yang lebih baik berkaitan dengan tingkat stres, kecemasan, dan burnout yang lebih rendah.

Hasil korelasi digunakan untuk memahami hubungan antarvariabel pada dataset dan mengidentifikasi faktor-faktor yang berkaitan dengan tingkat burnout mahasiswa. Namun, variabel *burnout_score*, *mental_health_index*, dan *dropout_risk* tidak digunakan dalam proses pemodelan karena memiliki hubungan yang sangat kuat dengan target dan berpotensi menyebabkan data leakage, sehingga dapat menghasilkan performa model yang terlalu optimistik.

7. Visualisasi Faktor Akademik terhadap Burnout (Scatter plot)



Gambar 8. Visualisasi Faktor Akademik terhadap Burnout


Gambar 8 menunjukkan hubungan antara *exam_pressure* dan *burnout_score* berdasarkan kategori *risk_level*. Terlihat bahwa semakin tinggi tekanan ujian (*exam pressure*), semakin tinggi pula kecenderungan nilai *burnout_score* yang diperoleh mahasiswa. Kelas Low didominasi oleh nilai burnout yang relatif rendah meskipun tingkat tekanan ujian bervariasi,

sedangkan kelas Medium dan High cenderung muncul pada kombinasi tekanan ujian dan skor burnout yang lebih tinggi.

Selain itu, titik-titik pada kelas High lebih banyak terkonsentrasi pada area dengan exam_pressure tinggi, yang mengindikasikan bahwa tekanan akademik berkontribusi terhadap peningkatan risiko burnout mahasiswa. Temuan ini juga sejalan dengan hasil analisis korelasi yang menunjukkan adanya hubungan positif antara exam_pressure dan burnout_score. Visualisasi ini dilakukan pada tahap Exploratory Data Analysis (EDA) untuk memahami pola hubungan antarvariabel sebelum proses seleksi fitur dan penghapusan fitur yang berpotensi menyebabkan data leakage dilakukan pada tahap pemodelan.

3.2 Hasil Eksperimen

1. SVM Baseline



Gambar 9. Confusion Matrix SVM Baseline

Berdasarkan Gambar 9, model SVM Baseline mampu mengklasifikasikan sebagian besar data pada kelas Low dengan benar, yaitu sebanyak 70.567 data dari total 76.664 data aktual. Pada kelas Medium, model berhasil memprediksi 9.908 data dengan benar, namun masih terdapat kesalahan prediksi yang cukup besar, yaitu 6.127 data Medium diprediksi sebagai Low dan 5.793 data Medium diprediksi sebagai High. Pada kelas High, model mampu memprediksi 1.390 data dengan benar dari total 1.508 data aktual, sehingga menunjukkan kemampuan yang baik dalam mengenali kelas risiko tinggi. Namun, kesalahan prediksi pada kelas Medium menunjukkan bahwa model masih mengalami kesulitan dalam membedakan karakteristik antara kelas Medium dengan kelas Low dan High.


Tabel 2. Hasil Evaluasi SVM Baseline

Metrik	Nilai
Accuracy	0.82
Precision Macro	0.58
Recall Macro	0.77
F1-Score Macro	0.58

Berdasarkan Tabel 2, model SVM Baseline memperoleh nilai accuracy sebesar 82%, yang menunjukkan bahwa sebagian besar data berhasil diklasifikasikan dengan benar. Nilai Recall Macro sebesar 0,77 menunjukkan bahwa model cukup baik dalam mengenali seluruh kelas, terutama kelas High yang memperoleh recall tinggi sebesar 0,92. Namun, nilai Precision Macro sebesar 0,58 menunjukkan bahwa masih terdapat cukup banyak prediksi yang kurang tepat, terutama pada kelas High yang memiliki precision rendah sebesar 0,18. Nilai F1-Score Macro sebesar 0,58 menunjukkan bahwa performa model secara keseluruhan masih belum

seimbang, karena meskipun model sensitif dalam mendeteksi kelas High, model masih menghasilkan banyak kesalahan prediksi pada beberapa kelas.

2. SVM Tuned



Gambar 10. Confusion Matrix SVM Tuned

Berdasarkan Gambar 10, heatmap confusion matrix SVM Tuned menunjukkan hasil prediksi yang sama dengan SVM Baseline. Model mampu mengklasifikasikan kelas Low dengan benar sebanyak 70.568 data, sedangkan 5.684 data Low diprediksi sebagai Medium dan 412 data Low diprediksi sebagai High. Pada kelas Medium, sebanyak 9.908 data berhasil diprediksi dengan benar, tetapi masih terdapat kesalahan cukup besar karena 6.127 data Medium diprediksi sebagai Low dan 5.793 data Medium diprediksi sebagai High. Pada kelas High, model berhasil mengenali 1.390 data dengan benar dari total 1.508 data, sehingga model cukup sensitif dalam mendeteksi kelas High meskipun masih terdapat sebagian kecil data High yang diprediksi sebagai Medium.

Tabel 3. Hasil Evaluasi SVM Tuned

Metrik	Nilai
Accuracy	0.82
Precision Macro	0.58
Recall Macro	0.77
F1-Score Macro	0.58

Berdasarkan Tabel 3, model SVM Tuned memperoleh nilai accuracy sebesar 82%, sama seperti hasil pada SVM Baseline. Nilai Recall Macro sebesar 0,77 menunjukkan bahwa model cukup baik dalam mengenali kelas secara keseluruhan, terutama kelas High yang memiliki recall sebesar 0,92. Namun, nilai Precision Macro sebesar 0,58 menunjukkan bahwa masih terdapat banyak prediksi yang kurang tepat, khususnya pada kelas High yang memiliki precision rendah sebesar 0,18. Nilai F1-Score Macro sebesar 0,58 menunjukkan bahwa performa model belum sepenuhnya seimbang karena model sangat sensitif terhadap kelas High, tetapi masih menghasilkan cukup banyak kesalahan prediksi pada kelas lain.


Tabel 4. Parameter Terbaik SVM Tuned

Parameter	Nilai
C	0.1
Loss	Squared_hinge

Max_iter**3000**

Berdasarkan tabel 4, parameter terbaik untuk model SVM adalah $C = 0.1$, $\text{loss} = \text{squared_hinge}$, dan $\text{max_iter} = 3000$. Nilai C yang lebih besar menunjukkan bahwa model memberikan penalti lebih besar terhadap kesalahan klasifikasi, sedangkan squared_hinge digunakan sebagai fungsi loss dalam proses optimasi LinearSVC. Meskipun parameter terbaik sudah diperoleh melalui RandomizedSearchCV, hasil evaluasi SVM Tuned tetap sama dengan SVM Baseline. Hal ini menunjukkan bahwa proses tuning belum memberikan peningkatan performa yang signifikan karena model SVM sudah mencapai performa yang relatif stabil pada data yang digunakan.

3. Random Forest Baseline



Gambar 11. Confusion Matrix Random Forest Baseline

Berdasarkan Gambar 11, model Random Forest Baseline mampu mengklasifikasikan sebagian besar data dengan benar, terutama pada kelas Low yang merupakan kelas mayoritas dalam dataset. Sebanyak 65.500 data pada kelas Low berhasil diprediksi dengan tepat. Pada kelas Medium, sebanyak 16.604 data berhasil diklasifikasikan dengan benar, sedangkan pada kelas High terdapat 923 data yang terprediksi dengan tepat.

Namun demikian, masih terdapat sejumlah kesalahan klasifikasi. Pada kelas Low, terdapat 11.136 data Medium dan 28 data High yang salah diprediksi sebagai Low. Pada kelas Medium, terdapat kesalahan prediksi ke kelas Low sebanyak 3.701 data dan ke kelas High sebanyak 1.523 data. Sementara itu, pada kelas High masih terdapat 584 data yang salah diprediksi sebagai Medium dan 1 data sebagai Low. Hal ini menunjukkan bahwa model masih mengalami kesulitan dalam membedakan kelas Medium dan High yang memiliki karakteristik fitur yang relatif mirip.


Tabel 5. Hasil Evaluasi Random Forest Baseline

Metrik	Nilai
Accuracy	0,83
Precision Macro	0,64
Recall Macro	0,74
F1-Score Macro	0,67

Berdasarkan Tabel 5, model Random Forest Baseline memperoleh accuracy sebesar 83%, yang menunjukkan bahwa sebagian besar data berhasil diklasifikasikan dengan benar. Nilai Recall Macro sebesar 0,74 menunjukkan bahwa model cukup baik dalam mengenali seluruh kelas secara keseluruhan. Sementara itu, Precision Macro sebesar 0,64 menunjukkan masih

terdapat beberapa kesalahan prediksi pada masing-masing kelas. Nilai F1-Score Macro sebesar 0,67 mengindikasikan bahwa performa model cukup seimbang, meskipun data memiliki ketidakseimbangan distribusi kelas.

4. Random Forest Tuned



Gambar 12. Confusion Matrix Random Forest Tuned

Berdasarkan Gambar 12, model Random Forest setelah dilakukan hyperparameter tuning menunjukkan peningkatan performa dibandingkan model baseline. Sebanyak 66.403 data pada kelas Low berhasil diprediksi dengan benar, sedangkan pada kelas Medium terdapat 16.567 data yang berhasil diklasifikasikan dengan tepat. Pada kelas High, sebanyak 867 data berhasil diprediksi dengan benar.

Meskipun demikian, masih terdapat kesalahan prediksi yang terjadi, namun jumlahnya cenderung lebih rendah dibandingkan model baseline pada beberapa kasus. Pada kelas Low, terdapat 10.243 data Medium dan 18 data High yang masih salah diklasifikasikan sebagai Low. Pada kelas Medium, terdapat 4.037 data yang salah diprediksi sebagai Low dan 1.224 data sebagai High. Sementara itu, pada kelas High masih terdapat 639 data yang diprediksi sebagai Medium dan 2 data sebagai Low. Secara umum, hasil ini menunjukkan bahwa proses tuning mampu membantu model dalam menangkap pola data dengan lebih baik sehingga menghasilkan prediksi yang lebih stabil.

Tabel 6. Hasil Evaluasi Random Forest Tuned

Metrik	Nilai
Accuracy	0,84
Precision Macro	0,65
Recall Macro	0,73
F1-Score Macro	0,68

Berdasarkan Tabel 6, model Random Forest Tuned memperoleh accuracy sebesar 84%, meningkat dibandingkan model baseline yang sebesar 83%. Selain itu, nilai F1-Score Macro juga meningkat menjadi 0,68, yang menunjukkan adanya peningkatan keseimbangan performa antar kelas. Nilai Precision Macro sebesar 0,65 juga mengalami peningkatan, yang menandakan bahwa model menjadi lebih akurat dalam melakukan prediksi pada masing-masing kelas. Meskipun terdapat sedikit penurunan pada Recall Macro dibandingkan model baseline, secara keseluruhan Random Forest Tuned menunjukkan performa yang lebih stabil dan seimbang.

Tabel 7. Parameter Terbaik Random Forest


Parameter	Nilai
-----------	-------

n_estimators	200
max_depth	30
min_samples_split	5
min_samples_leaf	2
max_features	log2

Parameter pada Tabel 7 merupakan kombinasi terbaik yang diperoleh dari proses hyperparameter tuning menggunakan RandomizedSearchCV. Parameter tersebut digunakan untuk membangun model Random Forest Tuned yang menghasilkan performa optimal pada penelitian ini.

5. Learning Curve


A. Learning Curve SVM



Gambar 13. Learning Curve SVM

Berdasarkan hasil learning curve, model SVM menunjukkan nilai F1 Macro pada data pelatihan dan validasi yang relatif berdekatan. Seiring bertambahnya proporsi data pelatihan yang digunakan dalam proses evaluasi, nilai F1 Macro cenderung stabil pada kisaran 0,58. Selisih yang kecil antara kurva pelatihan dan validasi menunjukkan bahwa model memiliki kemampuan generalisasi yang cukup baik dan tidak mengalami overfitting maupun underfitting secara signifikan. Stabilitasnya kedua kurva juga mengindikasikan bahwa performa model tidak banyak berubah meskipun menggunakan ukuran data pelatihan yang berbeda.

B. Learning Curve Random Forest



Gambar 14. Learning Curve Random Forest

Learning curve model random forest menunjukkan nilai F1 Macro pada data pelatihan yang sangat tinggi, yaitu sekitar 0,98, sedangkan nilai F1 Macro pada data validasi hanya berada pada kisaran 0,68–0,69. Perbedaan yang cukup besar antara kedua kurva mengindikasikan adanya kecenderungan overfitting, di mana model sangat baik dalam mempelajari data pelatihan tetapi kemampuan generalisasinya lebih rendah pada data validasi. Meskipun demikian, nilai F1 Macro validasi Random Forest tetap lebih tinggi dibandingkan SVM, sehingga model ini memiliki performa klasifikasi yang lebih baik pada penelitian ini.

6. Feature Importance

Tabel 8. Top 10 Feature Importance SVM

No	Fitur	Importance
1	Num_stress_level	0.447513
2	Num_social_support	0.216254
3	Num_sleep_hours	0.214271
4	Num_anxiety_score	0.211105
5	Num_exam_pressure	0.147335
6	Num_depression_score	0.131873
7	Gender_gender_other	0.093569
8	Num_internet_usage	0.019979
9	Num_financial_stress	0.016566
10	Num_screen_time	0.015417

Tabel 9. Top 10 Feature Importance RF

No	Fitur	Importance
1	Num_stress_level	0.253468
2	Num_anxiety_score	0.154295
3	Num_depression_score	0.138115
4	Num_sleep_hours	0.077036
5	Num_exam_pressure	0.060863
6	Num_social_support	0.059550
7	Num_study_hours_per_day	0.037226
8	Num_financial_stress	0.033931
9	Num_family_expectation	0.028622
10	Num_physical_activity	0.027181

Berdasarkan hasil feature importance pada model Random Forest dan SVM, kedua model menunjukkan pola yang relatif serupa dalam mengidentifikasi faktor-faktor penting yang memengaruhi tingkat risiko burnout mahasiswa. Variabel stress_level menjadi fitur paling dominan pada kedua model dengan nilai importance tertinggi, diikuti oleh beberapa variabel psikologis dan akademik seperti anxiety_score, depression_score, sleep_hours, exam_pressure, dan social_support. Hasil ini menunjukkan bahwa kondisi psikologis mahasiswa merupakan faktor utama dalam menentukan tingkat risiko burnout.

Meskipun terdapat perbedaan urutan tingkat kepentingan antar fitur, kedua model secara konsisten menempatkan variabel yang berkaitan dengan stres, kecemasan, kualitas tidur, tekanan akademik, dan dukungan sosial sebagai faktor yang paling berpengaruh. Pada

model SVM, fitur gender_gender_Other, internet_usage, dan screen_time juga muncul dalam sepuluh fitur teratas, sedangkan pada Random Forest muncul study_hours_per_day, family_expectation, dan physical_activity. Temuan ini menunjukkan bahwa kedua model memiliki kesamaan dalam mengidentifikasi faktor utama burnout mahasiswa, meskipun terdapat perbedaan dalam penilaian kontribusi beberapa fitur pendukung.

7. Model Comparison

Tabel 10. Hasil Perbandingan Model

Model	Accuracy	Precision Macro	Recall Macro	F1 Macro	Recall High
SVM Baseline	0.81865	0.577960	0.765378	0.584532	0.921751
SVM Tuned	0.81866	0.577974	0.765382	0.584539	0.921751
RF Baseline	0.83027	0.635267	0.742374	0.674606	0.612069
RF Tuned	0.83837	0.654238	0.733356	0.684866	0.574934

Berdasarkan Tabel 10, model SVM Baseline menghasilkan nilai accuracy sebesar 0,81865, Precision Macro sebesar 0,57796, Recall Macro sebesar 0,76538, F1 Macro sebesar 0,58453, dan Recall High sebesar 0,92175. Setelah dilakukan hyperparameter tuning, model SVM Tuned menghasilkan accuracy sebesar 0,81866, Precision Macro sebesar 0,57797, Recall Macro sebesar 0,76538, F1 Macro sebesar 0,58454, dan Recall High sebesar 0,92175. Meskipun terdapat sedikit peningkatan pada beberapa metrik evaluasi, perbedaannya sangat kecil sehingga dapat dikatakan bahwa proses tuning belum memberikan peningkatan performa yang signifikan dibandingkan model baseline. SVM memiliki nilai Recall High tertinggi di antara seluruh model, yang menunjukkan kemampuan sangat baik dalam mendeteksi kelas High. Namun, nilai Precision Macro dan F1 Macro yang relatif rendah menunjukkan bahwa model masih menghasilkan cukup banyak kesalahan prediksi, terutama karena cenderung terlalu sensitif dalam memprediksi kelas High. Dengan demikian, SVM cukup baik dalam mendeteksi mahasiswa dengan risiko burnout tinggi, tetapi performanya masih kurang seimbang untuk seluruh kelas target.

Model Random Forest Baseline memperoleh accuracy sebesar 0,83027, Precision Macro sebesar 0,63527, Recall Macro sebesar 0,74237, F1 Macro sebesar 0,67461, dan Recall High sebesar 0,61207. Setelah dilakukan hyperparameter tuning, model Random Forest Tuned mengalami peningkatan performa dengan accuracy sebesar 0,83837, Precision Macro sebesar 0,65244, dan F1 Macro sebesar 0,68487. Selain itu, Recall Macro juga meningkat menjadi 0,73336, yang menunjukkan kemampuan model yang lebih baik dalam mengklasifikasikan seluruh kelas secara lebih seimbang. Meskipun nilai Recall High pada RF Tuned sedikit lebih rendah dibandingkan RF Baseline, model ini menghasilkan nilai accuracy, Precision Macro, dan F1 Macro tertinggi dibandingkan model lainnya. Hasil tersebut menunjukkan bahwa Random Forest Tuned memiliki kemampuan yang lebih baik dalam menjaga keseimbangan performa antar kelas pada dataset yang tidak seimbang. Oleh karena itu, Random Forest Tuned dipilih sebagai model terbaik karena mampu memberikan performa klasifikasi yang paling stabil dan seimbang dalam mengidentifikasi kategori risiko burnout mahasiswa, yaitu Low, Medium, dan High.

Tabel 11. Contoh Perbandingan Label Aktual dan Prediksi Model

Index	Actual	SVM Baseline	SVM Tuned	RF Baseline	RF Tuned
77038	Low	Low	Low	Low	Low
454208	Medium	Low	Low	Medium	Medium
474868	Medium	Low	Low	Medium	Medium
73093	Low	Medium	Medium	Medium	Medium
312378	Low	Low	Low	Low	Low

Berdasarkan tabel 11, contoh hasil prediksi, setiap model menghasilkan prediksi yang berbeda terhadap data aktual pada beberapa sampel. Pada beberapa data dengan label aktual Low, seluruh model mampu memberikan prediksi yang tepat, sedangkan pada data aktual Medium, model SVM cenderung memprediksi sebagai Low. Random Forest terlihat lebih mampu mengenali beberapa data kelas Medium dibandingkan SVM, sehingga hasil prediksinya lebih seimbang pada sebagian sampel. Hal ini mendukung hasil evaluasi bahwa Random Forest Tuned memiliki performa keseluruhan yang lebih baik dibandingkan SVM Baseline maupun SVM Tuned.

4. Kesimpulan dan Saran

1. Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa faktor akademik dan psikologis memiliki pengaruh yang signifikan terhadap tingkat risiko burnout mahasiswa. Hasil analisis feature importance menunjukkan bahwa variabel stress_level, anxiety_score, depression_score, sleep_hours, exam_pressure, dan social_support merupakan faktor utama yang paling berkontribusi dalam menentukan tingkat risiko burnout. Selain itu, berdasarkan hasil perbandingan model, Random Forest Tuned dipilih sebagai model terbaik karena menghasilkan performa yang paling optimal dan seimbang dengan nilai Accuracy sebesar 83,84%, Precision Macro sebesar 65,42%, dan F1 Macro sebesar 68,49%. Meskipun model SVM memiliki kemampuan lebih baik dalam mendeteksi kelas High dengan Recall High sebesar 92,18%, performanya secara keseluruhan masih kurang seimbang karena nilai Precision Macro dan F1 Macro yang lebih rendah. Oleh karena itu, Random Forest Tuned dianggap sebagai model paling optimal dalam klasifikasi risiko burnout mahasiswa karena mampu memberikan keseimbangan performa yang lebih baik pada seluruh kelas (Low, Medium, dan High).

2. Saran

Berdasarkan hasil penelitian yang telah dilakukan, penelitian selanjutnya disarankan untuk menggunakan dataset yang berasal dari kondisi nyata mahasiswa agar hasil yang diperoleh lebih representatif terhadap situasi sebenarnya. Selain itu, dapat dilakukan perbandingan dengan algoritma lain seperti XGBoost, LightGBM, CatBoost, atau Neural Network untuk memperoleh performa yang lebih optimal. Pengembangan metode penanganan data tidak seimbang juga dapat dilakukan menggunakan teknik oversampling atau ensemble lainnya guna meningkatkan kemampuan model dalam mengenali kelas minoritas. Hasil penelitian ini diharapkan dapat menjadi dasar dalam pengembangan sistem deteksi dini burnout mahasiswa sehingga institusi pendidikan dapat melakukan langkah pencegahan dan

pendampingan secara lebih efektif terhadap mahasiswa yang berisiko mengalami burnout.

5. Daftar Pustaka

- [1] R. A. Rahman, K. Omar, S. A. Mohd Noah, M. S. N. Mohd Danuri, and M. A. Al-Garadi, "Application of machine learning methods in mental health detection: A systematic review," IEEE Access, vol. 8, pp. 183952–183964, 2020, doi: [10.1109/ACCESS.2020.3026454](https://doi.org/10.1109/ACCESS.2020.3026454).
- [2] A. Adinegara and S. Widodo, "Prediksi academic burnout pada mahasiswa: Analisis komparatif algoritma support vector machine dan random forest," MALCOM: Indonesian Journal of Machine Learning and Computer Science, vol. 5, no. 4, 2025, doi: [10.57152/malcom.v5i4.2283](https://doi.org/10.57152/malcom.v5i4.2283)
- [3] J. J. Hidayat, F. F. Azhari, T. M. Husna, A. N. Fahmayani, N. N. Pradana, and C. Setyowati, "Perbandingan kinerja algoritma machine learning dalam prediksi kesehatan mental dan burnout mahasiswa," Jurnal Sains dan Informatika, vol. 16, no. 1, 2026, Available: https://jurnal.umpp.ac.id/index.php/surya_informatika/article/view/2420
- [4] Z. Fatah and U. Hasanah, "Prediksi tingkat stress dan kesehatan mental mahasiswa menggunakan algoritma SVM," Jurnal Mahasiswa Teknik Informatika dan Komputer (JAMASTIKA), vol. 4, no. 2, 2025, doi: [10.35473/jamastika.v4i2.4542](https://doi.org/10.35473/jamastika.v4i2.4542).
- [5] Q. Li and J. Zhou, "A comparative analysis of extreme gradient boosting, decision tree, support vector machines, and random forest algorithm in data analysis of college students' psychological health," Informatica, vol. 49, no. 15, 2025, doi: [10.31449/inf.v49i15.7004](https://doi.org/10.31449/inf.v49i15.7004).
- [6] M. Chanafy and H. Sulistiani, "Comparative analysis of machine learning algorithm performance for student mental health classification," SMATIKA Jurnal, vol. 16, no. 1, 2026. [Online]. Available: <https://jurnal.ubhinus.ac.id/index.php/SMATIKA/article/view/2080/1097>
- [7] M. Fadhilla, R. Wandri, A. Hanafiah, P. R. Setiawan, Y. Arta, and S. Daulay, "Analisis performa algoritma machine learning untuk identifikasi depresi pada mahasiswa," Jurnal Media Informatika Budidarma, vol. 5, no. 1, 2025, Available: <https://hostjournals.com/jimat/article/view/473>
- [8] N. Nurdiansyah, F. S. Febriyan, Z. G. D. Amanta, D. A. Saputra, and W. M. Baihaqi, "Analisis kesehatan mental untuk mencegah gangguan mental pada mahasiswa menggunakan algoritma k-nearest neighbor (K-NN) dan random forest," MALCOM: Indonesian Journal of Machine Learning and Computer Science, vol. 5, no. 1, 2025, doi: [10.57152/malcom.v5i1.1537](https://doi.org/10.57152/malcom.v5i1.1537).
- [9] J. Jayadi, V. H. C. Putra, A. R. Raharja, and M. Al-Husaini, "Deteksi dini kesehatan mental mahasiswa dengan machine learning: Perbandingan algoritma decision tree dan random forest," Technologia: Jurnal Ilmiah, vol. 17, no. 1, 2025, doi: [10.31602/tji.v17i1.21251](https://doi.org/10.31602/tji.v17i1.21251).
- [10] I. S. Maulana, S. D. Tiara, A. Y. Pratama, F. K. Sari, and I. Darmawan, "Prediksi risiko depresi pada mahasiswa menggunakan algoritma random forest berdasarkan data akademik dan gaya hidup," Jurnal Sistem Informasi dan Teknologi Informasi Komputer, vol. 4, no. 1, 2025, doi: [10.53624/jsitik.v4i1.696](https://doi.org/10.53624/jsitik.v4i1.696).